Alan Joffre

Engenheiro de Dados e IA

Lakehouse em escala (Databricks · dbt · Delta Lake · Airflow) · Data Quality e governança · IA aplicada

São Paulo, SP · alanjoffre01@gmail.com · (11) 91547-2650 · linkedin.com/in/alanjoffre · github.com/alanjoffre/portfolio

RESUMO

Engenheiro de dados com 4 anos de experiência, com histórico de assumir produtos de dados de ponta a ponta: arquitetura, modelagem, orquestração, qualidade e entrega a gestores. No projeto mais recente, desenhei e entreguei um lakehouse em Databricks e dbt que processa dezenas de milhões de registros por mês e reduziu apurações de 20 para 2 dias. Trago também base em ciência de dados e engenharia de IA aplicada (RAG, fine-tuning e LLM em produção), útil para plataformas de dados que servem modelos e agentes.

COMPETÊNCIAS TÉCNICAS

- **Engenharia de dados:** Python, SQL, PySpark, Databricks (Unity Catalog, Delta Lake), dbt, Airflow, DuckDB, dlt, Kafka
- **Qualidade e governança:** dbt tests e contracts, Soda, OpenLineage, masking de PII, trilha de auditoria
- **Cloud e DevOps:** AWS (EC2, EBS, S3, IAM, Systems Manager, Glue, Redshift), Azure (ambiente Databricks), Docker, Terraform, GitHub Actions, CI/CD
- **Bancos e backend:** PostgreSQL, Redshift, BigQuery, FastAPI (assíncrono)
- **IA e ML:** LLMs (Claude), RAG, LangGraph, Qdrant, QLoRA, vLLM, PyTorch, Hugging Face, Scikit-learn, XGBoost, LightGBM
- **MLOps e avaliação:** MLflow, DVC, avaliação estatística (IC, McNemar), gates de CI
- **BI:** Power BI (DAX), Evidence.dev

EXPERIÊNCIA PROFISSIONAL

Consultor em Engenharia de Dados e IA — Ser Mais Digital fev/2025 – atual · São Paulo (híbrido)

Cliente de mobilidade e pagamentos (fev/2025 – set/2026): engenheiro de dados responsável pelo produto de auditoria e simulação de vale-pedágio, do desenho à entrega.

- Desenhei e implantei a arquitetura Medallion (Bronze/Silver/Gold) em Databricks (Azure), Unity Catalog e Delta Lake, modelada com dbt, reduzindo o tempo de apuração de até 20 para 2 dias (90%).
- Construí pipelines orquestrados no Airflow com retry, alertas e dependências, processando dezenas de milhões de transações e logs por mês, com camadas analíticas na casa dos bilhões de linhas.
- Implantei Data Quality com dbt tests e contracts, masking de PII, backup/restore versionado e KPIs auditáveis.
- Automatizei relatórios e análises para gestores, com governança de acesso, trilha de auditoria e exportação em CSV, XLSX, Parquet e PDF.

Cientista de Dados — SWM Consultoria out/2023 – jan/2025 · São Paulo (híbrido)

- Reduzi em 20% os custos logísticos de um cliente com um modelo preditivo de séries temporais.
- Aumentei em 18 pontos percentuais a acurácia de detecção de anomalias com visão computacional (YOLOv5 e OCR), cortando 40% do esforço manual.
- Entreguei projetos completos de classificação, clusterização e previsão com Scikit-learn, XGBoost e LightGBM, com explicabilidade (SHAP, LIME) apresentada a áreas técnicas e executivas.

Engenheiro de Dados — SWM Consultoria set/2022 – ago/2023 · São Paulo (híbrido)

- Reduzi em até 50% o tempo de ingestão e carga com pipelines ELT em AWS (S3, Glue, Redshift) e Apache Spark.
- Otimizei queries em Redshift, PostgreSQL e BigQuery, com ganhos de até 70% em tempo de execução.
- Automatizei ingestão e transformação com Python e jobs agendados no Airflow, eliminando etapas manuais.

PROJETOS

oss-lakehouse — lakehouse sobre dados reais do GitHub (open-source) · GitHub · guia de estudo

- Lakehouse bronze → silver → gold em PySpark e Delta Lake sobre 2 milhões de eventos reais do GitHub, com o mesmo código local e preparado para Databricks: job multi-tarefa em bundle validado e Azure (ADLS Gen2, identidade gerenciada, Key Vault, Unity Catalog) em Terraform.
- 18 notebooks executados com a evidência na célula (plano físico, métricas de MERGE, skew real de 12,7% de um único ator), pacote Python com 190 testes e CI: ingestão incremental, MERGE e SCD2, streaming, Delta Lake por dentro, governança e LGPD.

- IA dentro do pipeline com avaliação: classificação de PII e de títulos contra gabarito, regras de qualidade com aprovação humana e uma cascata em que uma regra simples resolve 36% dos casos sem chamar o modelo.

Toll Analytics Platform — plataforma de dados end-to-end (open-source, dados fictícios) · GitHub · dashboard ao vivo

- Pipeline dlt → dbt (Medallion, contracts, unit tests, Semantic Layer, dbt Mesh) → Airflow + Cosmos → Soda → OpenLineage → Evidence.dev; roda em DuckDB no dev e em Databricks no prod sem alterar o SQL.
- Streaming near-real-time com Kafka (Redpanda): produtor, consumidor em micro-batch e fato incremental.
- CI/CD com 10 workflows no GitHub Actions (Slim CI, gate de Data Quality, deploy com promoção staging → prod) e IaC do Databricks em Terraform.

Aira — plataforma SaaS de IA (projeto próprio, em produção na AWS) abr/2026 – atual

- Backend assíncrono em Python/FastAPI com PostgreSQL, multi-tenant, incluindo migração de banco em produção sem perda de dados.
- Integração de LLM (Claude) com controle de custo, RAG, masking de PII e trilha de auditoria com hash-chain.
- Infraestrutura AWS operada de ponta a ponta: 4 ambientes em EC2 (dev, produção, demo e administração) com Docker, Postgres e Caddy; deploys via Systems Manager, sem SSH exposto; backups automáticos em S3 antes de cada deploy e diariamente; acessos controlados por papéis IAM.

RodoIA — engenharia de IA de ponta a ponta (open-source) · github.com/alanjoffre/rodoia

- Processamento de 17,2 milhões de linhas com memória limitada; motor escolhido por benchmark (DuckDB 6,7× mais rápido que Spark, 0 divergências nos resultados).
- RAG avaliado sobre benchmark de terceiros (CUAD, 13.823 trechos anotados por advogados), com ganhos validados por intervalo de confiança e McNemar pareado.
- Fine-tuning QLoRA servido com vLLM (F1 de 0,13 para 0,77 em NER jurídico) e agente em LangGraph.
- Avaliação como gate de CI: 30 portões e 289 testes.

FORMAÇÃO ACADÊMICA

- **MBA em Inteligência Artificial** — Estácio · jul/2026 – jun/2027 (em andamento)
- **Especialização em Engenharia de Software com IA** — Universidade Anhanguera · jul/2026 – jan/2027 (em andamento)
- **Tecnólogo em Ciência de Dados** — Universidade Anhanguera · jan/2024 – jun/2026