Alan Joffre

Engenheiro de Dados

Lakehouse (Databricks · dbt · Delta Lake · Airflow) · Data Quality e governança · IA aplicada

São Paulo, SP · alanjoffre01@gmail.com · linkedin.com/in/alanjoffre · github.com/alanjoffre

RESUMO

Engenheiro de Dados com mais de 6 anos de experiência em dados e IA, dos quais mais de 5 anos em engenharia de dados: arquitetura, modelagem, orquestração, qualidade e governança de dados, com entrega a gestores. Alocado em cliente de mobilidade e pagamentos, desenhei e entreguei um lakehouse em Databricks e dbt que processava dezenas de milhões de registros por mês (1 bilhão por mês na principal tabela de eventos) e reduziu o tempo de apuração de até 20 para 2 dias. Hoje respondo pelo desenvolvimento e pela operação da Aira, produto de IA da Noron.dev (LLM com recuperação agêntica sobre arquivos, avaliação de IA, segurança e governança de dados). Mantenho projetos open source de dados, IA aplicada e back-end em Java.

COMPETÊNCIAS TÉCNICAS

Uso profissional

- **Engenharia de dados:** Python, SQL, Apache Spark (PySpark), Databricks (Unity Catalog, Delta Lake), dbt, Apache Airflow, Kafka, DuckDB, ETL/ELT, Data Warehouse e modelagem dimensional
- **Bancos e cloud:** PostgreSQL, Redshift, BigQuery, AWS (EC2, S3, IAM, Glue), Azure (Databricks), Docker, Terraform, Git, GitHub Actions
- **Qualidade e governança:** dbt tests e contracts, masking de PII (LGPD), trilha de auditoria, KPIs auditáveis
- **IA, ML e back-end:** LLM, RAG, FastAPI (assíncrono), SvelteKit, TypeScript, Machine Learning (ML), Scikit-learn, XGBoost, LightGBM, visão computacional (YOLOv5, OCR), SHAP
- **BI:** Power BI (DAX)

Em projetos abertos

- **Dados:** dlt, Soda, OpenLineage, Evidence.dev, Debezium (CDC)
- **IA e MLOps:** LangGraph, Qdrant, QLoRA, vLLM, PyTorch, Hugging Face, MLflow, DVC, avaliação estatística (intervalo de confiança, teste de McNemar)
- **Back-end e front-end:** Java (Spring Boot, Quarkus), MongoDB; React e TypeScript

EXPERIÊNCIA PROFISSIONAL

Engenheiro de Dados e IA — Noron.dev (antiga Ser Mais Digital) fev/2025 – atual · São Paulo (híbrido)

Aira, produto de IA da Noron.dev (abr/2026 – atual): respondo pelo desenvolvimento e pela operação de uma plataforma de IA corporativa em que cada pessoa pergunta, em português, sobre os arquivos da própria empresa e recebe a resposta com as fontes, em instância dedicada por cliente. Oferecida ao mercado pela Noron.dev no CONARH 2026.

- Conduzi o desenvolvimento do assistente de IA (LLM com recuperação agêntica nos arquivos da empresa, fontes citadas, somente leitura, restrito às pastas que cada pessoa tem permissão de ver), dos agentes agendados com envio por e-mail e da geração de relatórios em Excel, Word, PDF e PowerPoint.
- Conduzi a criação do conjunto de avaliação da IA (mais de 30 casos em 7 categorias, conferidores determinísticos, comparação antes e depois), executado antes de mudar prompt, modelo ou esforço; cobre dado ausente, injeção de prompt e confinamento de leitura.
- Respondo pelo desenho de segurança e governança de dados: permissões por pasta e perfil, auditoria encadeada por SHA-256, mascaramento de dados pessoais, segredos cifrados, retenção automática e backup diário cifrado fora do servidor.
- Respondo pelo back-end assíncrono em Python/FastAPI e PostgreSQL, incluindo a migração de SQLite para PostgreSQL em produção, conferida tabela a tabela; Docker na AWS, com deploy só após backup externo confirmado.

Cliente de mobilidade e pagamentos (fev/2025 – set/2026): engenheiro de dados responsável pelo produto de auditoria e simulação de custos de transporte, do desenho à entrega.

- Desenhei e implantei a arquitetura Medallion (bronze, silver e gold) em Databricks (Azure), Unity Catalog e Delta Lake, modelada com dbt, reduzindo o tempo de apuração de até 20 para 2 dias.
- Construí pipelines orquestrados no Airflow com novas tentativas (retry), alertas e dependências, processando dezenas de milhões de transações e logs por mês; a principal tabela de eventos chega a 1 bilhão de registros mensais.
- Implantei Data Quality com dbt tests e contracts, masking de PII, backup e restauração versionados e KPIs auditáveis.
- Automatizei relatórios e análises para gestores, com governança de acesso, trilha de auditoria e exportação em CSV, XLSX, Parquet e PDF.
- Construí uma ferramenta de IA com RAG para o treinamento da equipe comercial; aprovada e em produção.

Cientista de Dados — SWM Consultoria out/2023 – jan/2025 · São Paulo (híbrido)

- Reduzi em 20% os custos logísticos de um cliente com um modelo preditivo de séries temporais.
- Aumentei em 18 pontos percentuais a acurácia de detecção de anomalias com visão computacional (YOLOv5 e OCR), cortando 40% do esforço manual.
- Entreguei projetos completos de classificação, clusterização e previsão com Scikit-learn, XGBoost e LightGBM, e explicabilidade (SHAP, LIME) apresentada a públicos técnicos e executivos.

Engenheiro de Dados — SWM Consultoria jun/2020 – ago/2023 · São Paulo (híbrido)

- Reduzi em até 50% o tempo de ingestão e carga com pipelines ELT na AWS (S3, Glue, Redshift) e Apache Spark.
- Otimizei consultas SQL em Redshift, PostgreSQL e BigQuery, com ganhos de até 70% em tempo de execução.
- Automatizei ingestão e transformação com Python e jobs agendados no Airflow, eliminando etapas manuais, e ingestão em tempo real com Kafka.
- Infraestrutura como código em Terraform e dashboards em Power BI para as áreas de negócio.
- Modelei o Data Warehouse no Redshift (fatos e dimensões) e o data lake no S3 em Parquet, particionado e catalogado no Glue, com consulta pelo Athena.
- Implementei cargas incrementais e CDC com reprocessamento idempotente, validações de Data Quality e alertas de falha.

PROJETOS

Open source, com dados públicos ou sintéticos e apoio de assistente de IA. Todos os projetos: github.com/alanjoffre/portfolio

oss-lakehouse — lakehouse sobre dados reais do GitHub · github.com/alanjoffre/oss-lakehouse · guia de estudo

- Lakehouse bronze, silver e gold em PySpark e Delta Lake sobre eventos reais do GitHub; o mesmo código roda localmente e no Databricks. Infraestrutura Azure (ADLS Gen2, Key Vault, Unity Catalog) em Terraform, verificada com terraform validate, sem apply.
- 18 notebooks executados e mais de 180 testes com CI: MERGE e SCD2, streaming, governança e LGPD, e IA dentro do pipeline avaliada contra gabarito.

toll-analytics-platform — plataforma de dados · github.com/alanjoffre/toll-analytics-platform · dashboard ao vivo

- Construída do zero com dados sintéticos: dlt, dbt (Medallion, contracts, Semantic Layer, dbt Mesh), Airflow com Cosmos, Soda e Evidence.dev; executada em DuckDB e desenhada para Databricks sem mudar o SQL.
- CI/CD com 10 workflows no GitHub Actions (Slim CI, gate de Data Quality, promoção de staging para produção) e infraestrutura do Databricks em Terraform, validada sem apply.

pg-cdc-lakehouse — CDC conferido contra a origem, com dado sintético · github.com/alanjoffre/pg-cdc-lakehouse

- PostgreSQL → Debezium → Kafka → Parquet e Delta Lake, com MERGE que só avança e estado final idempotente.
- 3 falhas injetadas e 1 operação normal: origem igual ao destino em contagem, chaves, conteúdo e hash.

RodoIA — engenharia de IA de ponta a ponta · github.com/alanjoffre/rodoia · demo ao vivo

- Fine-tuning QLoRA servido com vLLM (F1 de 0,13 para 0,77), agente em LangGraph e avaliação como gate de CI.

Outros: Ledgerly Bank — banco digital fictício em Java, com Pix em Saga e Outbox (1.141 testes); RodoQuery — Text-to-SQL sobre camada semântica (100% contra 44,5% do SQL direto, n=146; o 100% é teto do instrumento); NãoConsta — RAG contratual avaliado pelo que recusa responder.

FORMAÇÃO ACADÊMICA

- **Tecnólogo em Ciência de Dados** — Anhanguera · jan/2024 – jun/2026 (concluído)
- **MBA em Inteligência Artificial** — Estácio · jul/2026 – jun/2027 (em andamento)
- **Especialização em Engenharia de Software com IA** — Anhanguera · jul/2026 – jan/2027 (em andamento)

CURSOS E CERTIFICADOS

- **Databricks** — Databricks para Engenheiros de Dados; Databricks SQL e BI (mar/2025).
- **Udemy** — dbt: modelos, materializações, testes e macros; Apache Kafka e Databricks: Streaming e Processamento; Engenharia de Dados: Domine Big Data; Engenharia de Dados: ingestão e integração (PySpark, NiFi); Microsoft Power BI + Projetos Reais (abr/2025).
- **Udemy** — Preparação para o AWS Certified Cloud Practitioner, CLF-C02 (jan/2025).

IDIOMAS

Português (nativo) · Inglês (leitura de documentação técnica)