Alan Joffre

Engenheiro de Dados

Lakehouse (Databricks · dbt · Delta Lake · Airflow) · Data Quality e governança · IA aplicada
São Paulo, SP · alanjoffre01@gmail.com · linkedin.com/in/alanjoffre · github.com/alanjoffre

RESUMO

Engenheiro de Dados com mais de 6 anos de experiência em dados e IA, dos quais mais de 5 anos em engenharia de dados: arquitetura, modelagem, orquestração, qualidade e governança de dados, com entrega a gestores. Alocado em cliente de mobilidade e pagamentos, desenhei e entreguei um lakehouse em Databricks e dbt que processava dezenas de milhões de registros por mês (1 bilhão por mês na principal tabela de eventos) e reduziu o tempo de apuração de até 20 para 2 dias. Hoje sou o responsável técnico pelo desenvolvimento e pela operação da Aira, produto de IA da Noron.dev (LLM com recuperação agêntica sobre arquivos, avaliação de IA, segurança e governança de dados). Mantenho projetos open source de dados, IA aplicada e back-end em Java.

COMPETÊNCIAS TÉCNICAS

Uso profissional

- **Engenharia de dados:** Python, SQL, Apache Spark (PySpark), Databricks (Unity Catalog, Delta Lake), dbt, Apache Airflow, Kafka, DuckDB, ETL/ELT, Data Warehouse e modelagem dimensional
- **Bancos e cloud:** PostgreSQL, Redshift, BigQuery, AWS (EC2, S3, IAM, Glue), Azure (Databricks), Docker, Terraform, Git, GitHub Actions
- **Qualidade e governança:** dbt tests e contracts, masking de PII (LGPD), trilha de auditoria, KPIs auditáveis
- **IA, ML e back-end:** LLM, RAG, FastAPI (assíncrono), SvelteKit, TypeScript, Machine Learning (ML), Scikit-learn, XGBoost, LightGBM, visão computacional (YOLOv5, OCR), SHAP
- **BI:** Power BI (DAX)

Em projetos abertos

- **Dados:** dlt, Soda, OpenLineage, Evidence.dev
- **IA e MLOps:** LangGraph, Qdrant, QLoRA, vLLM, PyTorch, Hugging Face, MLflow, DVC, avaliação estatística (intervalo de confiança, teste de McNemar)
- **Back-end e front-end:** Java (Spring Boot, Quarkus), MongoDB; React e TypeScript

EXPERIÊNCIA PROFISSIONAL

Engenheiro de Dados e IA — Noron.dev (antiga Ser Mais Digital) fev/2025 – atual · São Paulo (híbrido)

Aira, produto de IA da Noron.dev (abr/2026 – atual): sou o responsável técnico pelo desenvolvimento e pela operação de uma plataforma de IA corporativa em que cada pessoa pergunta, em português, sobre os arquivos da própria empresa e recebe a resposta com as fontes, em instância dedicada por cliente. Oferecida ao mercado pela Noron.dev no CONARH 2026.

- Conduzi o desenvolvimento do assistente de IA (LLM com recuperação agêntica nos arquivos da empresa, fontes citadas, somente leitura, restrito às pastas de cada pessoa), dos agentes agendados com envio por e-mail e da geração de relatórios em Excel, Word, PDF e PowerPoint.
- Conduzi a criação do conjunto de avaliação da IA (mais de 30 casos em 7 categorias, conferidores determinísticos, comparação antes e depois), executado antes de mudar prompt, modelo ou esforço; cobre dado ausente, injeção de prompt e confinamento de leitura.
- Respondo pelo desenho de segurança e governança de dados: permissões por pasta e perfil, auditoria encadeada por SHA-256, mascaramento de dados pessoais, segredos cifrados, retenção automática e backup diário cifrado fora do servidor.
- Respondo pelo back-end assíncrono em Python/FastAPI e PostgreSQL, incluindo a migração de SQLite para PostgreSQL em produção, conferida tabela a tabela; Docker na AWS, com deploy só após backup externo confirmado.

Cliente de mobilidade e pagamentos (fev/2025 – set/2026): engenheiro de dados responsável pelo produto de auditoria e simulação de custos de transporte, do desenho à entrega.

- Desenhei e implantei a arquitetura Medallion (bronze, silver e gold) em Databricks (Azure), Unity Catalog e Delta Lake, modelada com dbt, reduzindo o tempo de apuração de até 20 para 2 dias.
- Construí pipelines orquestrados no Airflow com novas tentativas (retry), alertas e dependências, processando dezenas de milhões de transações e logs por mês; a principal tabela de eventos chega a 1 bilhão de registros mensais.
- Implantei Data Quality com dbt tests e contracts, masking de PII, backup e restauração versionados e KPIs auditáveis.
- Automatizei relatórios e análises para gestores, com governança de acesso, trilha de auditoria e exportação em CSV, XLSX, Parquet e PDF.

Cientista de Dados — SWM Consultoria out/2023 – jan/2025 · São Paulo (híbrido)

- Reduzi em 20% os custos logísticos de um cliente com um modelo preditivo de séries temporais.
- Aumentei em 18 pontos percentuais a acurácia de detecção de anomalias com visão computacional (YOLOv5 e OCR), cortando 40% do esforço manual.
- Entreguei projetos completos de classificação, clusterização e previsão com Scikit-learn, XGBoost e LightGBM, e explicabilidade (SHAP, LIME) apresentada a públicos técnicos e executivos.

Engenheiro de Dados — SWM Consultoria jun/2020 – ago/2023 · São Paulo (híbrido)

- Reduzi em até 50% o tempo de ingestão e carga com pipelines ELT na AWS (S3, Glue, Redshift) e Apache Spark.
- Otimizei consultas SQL em Redshift, PostgreSQL e BigQuery, com ganhos de até 70% em tempo de execução.
- Automatizei ingestão e transformação com Python e jobs agendados no Airflow, eliminando etapas manuais, e ingestão em tempo real com Kafka.
- Infraestrutura como código em Terraform e dashboards em Power BI para as áreas de negócio.
- Modelei o Data Warehouse no Redshift (fatos e dimensões) e o data lake no S3 em Parquet, particionado e catalogado no Glue, com consulta pelo Athena.
- Implementei cargas incrementais e CDC com reprocessamento idempotente, validações de Data Quality e alertas de falha nos pipelines.

PROJETOS

Open source, com dados públicos ou sintéticos e apoio de assistente de IA. Todos os projetos: github.com/alanjoffre/portfolio

oss-lakehouse — lakehouse sobre dados reais do GitHub · github.com/alanjoffre/oss-lakehouse · guia de estudo

- Lakehouse bronze, silver e gold em PySpark e Delta Lake sobre eventos reais do GitHub; o mesmo código roda localmente e no Databricks. Infraestrutura Azure (ADLS Gen2, Key Vault, Unity Catalog) em Terraform, verificada com terraform validate, sem apply.
- 18 notebooks executados e mais de 180 testes com CI: MERGE e SCD2, streaming, governança e LGPD, e IA dentro do pipeline avaliada contra gabarito.

toll-analytics-platform — plataforma de dados · github.com/alanjoffre/toll-analytics-platform · dashboard ao vivo

- Construída do zero com dados sintéticos: dlt, dbt (Medallion, contracts, Semantic Layer, dbt Mesh), Airflow com Cosmos, Soda e Evidence.dev; executada em DuckDB e desenhada para Databricks sem mudar o SQL.
- CI/CD com 10 workflows no GitHub Actions (Slim CI, gate de Data Quality, promoção de staging para produção) e infraestrutura do Databricks em Terraform, validada sem apply.

RodoIA — engenharia de IA de ponta a ponta · github.com/alanjoffre/rodoia · demo ao vivo

- Motor de dados escolhido por benchmark (DuckDB 6,7 vezes mais rápido que o Spark) e RAG avaliado com intervalo de confiança e teste de McNemar pareado.
- Fine-tuning QLoRA servido com vLLM (F1 de 0,13 para 0,77 em NER jurídico), agente em LangGraph e avaliação como gate de CI.

Outros: Ledgerly Bank — banco digital fictício em Java, com Pix em Saga e Outbox (1.141 testes); RodoQuery — Text-to-SQL sobre camada semântica (100% contra 44,5% do SQL direto); NãoConsta — RAG contratual avaliado pelo que recusa responder.

FORMAÇÃO ACADÊMICA

- **Tecnólogo em Ciência de Dados** — Anhanguera · jan/2024 – jun/2026 (concluído)
- **MBA em Inteligência Artificial** — Estácio · jul/2026 – jun/2027 (em andamento)
- **Especialização em Engenharia de Software com IA** — Anhanguera · jul/2026 – jan/2027 (em andamento)

CURSOS E CERTIFICADOS

- **Databricks** — Databricks para Engenheiros de Dados; Databricks SQL e BI (mar/2025).
- **Udemy** — dbt: modelos, materializações, testes e macros; Apache Kafka e Databricks: Streaming e Processamento; Engenharia de Dados: Domine Big Data; Engenharia de Dados: ingestão e integração (PySpark, NiFi); Microsoft Power BI + Projetos Reais (abr/2025).
- **Udemy** — Preparação para o AWS Certified Cloud Practitioner, CLF-C02 (jan/2025).

IDIOMAS

Português (nativo) · Inglês (leitura de documentação técnica)